

NYC Yellow Taxi (2026-05) 원본 데이터 시각화 분석 보고서

- 대상 노트북: 02_visualization_original.ipynb
- 데이터: 2026-05 Yellow Taxi trip 원본 parquet, 정제(cleaning) 없이 그대로 분석
- 행/열 수: 4,090,836행 × 20열
- 작성 방식: 노트북을 처음부터 끝까지 실행한 실제 출력값·차트를 기반으로 작성 (추정치 없음)

0. 핵심 요약 (TL;DR)

항목	내용
결측치	5개 컬럼(23.35%)이 완전히 같은 행에서 결측 — 무작위가 아니라 특정 레코드 유형
결측 원인 후보	결측 행 = <code>payment_type == 0</code> 인 행과 100% 일치, <code>VendorID == 6</code> 은 전부 결측 행에만 존재
데이터 품질	음수 금액 1.4만여 건, <code>trip_distance ≤ 0</code> 11.3만 건, 소요시간 ≤ 0 5.2만 건
극단 이상치	<code>trip_distance</code> 최댓값 307,491마일(지구 12바퀴 이상) — 명백한 입력 오류
상관관계 함정	<code>trip_distance</code> vs <code>fare_amount</code> 상관계수가 0.01(거의 무관) — 극단 이상치가 실제 관계를 가림
지역 편중	전체 트립의 86.5%가 Manhattan에서 출발

1. 데이터 로딩 — Pandas vs Polars

관찰

- 두 라이브러리 모두 동일하게 4,090,836행 × 20열 로딩, 행 수/결측치 수 100% 일치
- 로딩 속도: Polars 0.065초 vs Pandas 0.125초 (Polars가 약 2배 빠름)



해석: 이후 분석은 시각화 생태계가 성숙한 Pandas(pdf)로 통일해도 결과 신뢰성에 문제 없음.

Next Action: 없음 (검증 완료 단계)


2. 결측치 시각화 (missingno)

관찰

- 결측 컬럼: `passenger_count`, `RatecodeID`, `store_and_fwd_flag`, `congestion_surcharge`, `Airport_fee` — 5개 전부 정확히 955,371건 (23.35%)



- heatmap의 5개 컬럼 쌍 모두 상관계수 1.00 → 결측이 같은 행에서 동시에 발생




- 추가로 직접 확인한 결과: 이 955,371개 결측 행은 `payment_type == 0` 인 행과 **완전히 일치**(100%)하며, `VendorID == 6` (7,643건)은 전부 이 결측 그룹에만 존재하고 `VendorID == 7` (51,750건)은 전부 비결측 그룹에만 존재

해석: 무작위 결측(MCAR)이 아니라, **특정 벤더/기록 방식의 트립이 통째로 5개 필드를 채우지 않는 구조적 결측**. `payment_type=0` 이 "결제 방식 미정" 같은 특수 상태를 의미할 가능성이 높고, 이 값이 있는 행은 부가 정보(승객 수, 요금 유형, 통행료 정산 여부 등)를 아예 기록하지 않는 별도 파이프라인으로 들어왔을 것으로 추정됨.

Next Action

- 컬럼별 중앙값/최빈값 대체보다 **"이 행 그룹 자체를 어떻게 처리할지"** 를 먼저 결정 (별도 카테고리로 유지 vs 제외)
- `VendorID` 6/7은 `LABEL_MAP` 에 매핑이 없는 신규/미상 벤더 코드 — 매핑 테이블 업데이트 필요

3. 정제 전 데이터 품질 이슈 요약



관찰 (전체 4,090,836행 기준)

이슈	건수	비율
결측치 포함 행 (5개 컬럼 중 1개+)	955,371	23.35%
<code>trip_distance ≤ 0</code>	113,031	2.76%
소요시간(승차→하차) ≤ 0	52,063	1.27%
<code>total_amount</code> 음수	14,877	0.36%
<code>fare_amount</code> 음수	14,231	0.35%
<code>passenger_count = 0</code>	12,533	0.31%

해석: 음수 금액·거리 0 이하·소요시간 0 이하는 각각 1% 미만으로 비율은 작지만, 절대 건수로는 수만 건 단위. 단순 입력 오류일 수도, 취소/환불 트립일 수도 있어 일괄 삭제보다 원인별 분리가 필요.

Next Action: 정제(Part 3) 단계에서 처리할 항목 체크리스트로 그대로 사용 가능.

4. 컬럼 타입 분류 & 기술통계

관찰


- 수치형 11개, 범주형 5개(`store_and_fwd_flag` , `payment_type` , `RatecodeID` , `passenger_count` , `VendorID`), 날짜형 2개, 위치코드 2개
- `total_amount` : 평균 \$30.49, 중앙값 \$23.94, 최솟값 \$951, 최댓값 \$5,530.74
- `trip_distance` : 평균 4.95마일, 최댓값 307,491.5마일

해석: 평균이 중앙값보다 크게 높고(오른쪽 꼬리), min/max가 상식 밖의 값 — 정제 전 원본 데이터 특유의 "극단 이상치가 통계량을 왜곡하는" 전형적 사례.

Next Action: describe() 같은 요약 통계는 이상치 제거 전까지 참고용으로만 사용, 실제 의사결정엔 분위수(IQR) 기반 지표를 우선 사용.

5. 범주형 변수 분석

범주형 컬럼 분포 — Bar Chart



관찰

컬럼	최빈값	비율	비고
<code>payment_type</code>	1 (신용카드)	66.7%	0 (23.35%)은 라벨 매핑 없음 — 결측 그룹과 동일
<code>RatecodeID</code>	1.0 (표준)	90.7%	99 (기타) 4.5%, 6 (그룹)은 단 1건
<code>passenger_count</code>	1.0	82.2%	0 명 12,533건
<code>VendorID</code>	2 (VeriFone)	78.9%	6, 7 은 LABEL_MAP 미정의
<code>store_and_fwd_flag</code>	N	99.9%(비결측 중)	극단적으로 불균형

해석: `RatecodeID=6` (그룹, 1건), `store_and_fwd_flag` 편중은 예상 범위지만, `payment_type=0` 과 미매핑 `VendorID` 값은 위 결측 이슈와 직결된 데이터 정의 문제.

Next Action: LABEL_MAP 에 `VendorID: 6, 7` , `payment_type: 0` 라벨 추가(또는 "미상"으로 명시) 필요.


6. 수치형 분포 — 왜도/첨도, 히스토그램, 박스플롯

관찰

- 11개 수치형 컬럼 중 10개가 "강한 비대칭"(|왜도| > 1), 로그변환 권장


- **trip_distance** 왜도 386.6, 첨도 171,277 — 사실상 전 컬럼 중 최악의 왜곡 (307,491마일 이상치 1건 영향이 큼)

수치형 컬럼 분포 — 히스토그램 + KDE



- IQR 기준 이상치 비
 율: **trip_distance** 11.2%, **total_amount** 8.9%, **congestion_surcharge** 8.8%, **tolls_amount** 6.7%, **Airport_fee** 6.3%, **fare_amount** 6.5%
- **cbd_congestion_fee** 만 이상치 0건(값 종류가 2가지뿐인 이진성 변수라 IQR 자체가 무의미)

수치형 컬럼 박스플롯 — IQR 이상치 탐지




해석: 거의 모든 금액/거리 컬럼이 소수의 극단값에 의해 분포가 심하게 왜곡됨. 특히 `trip_distance` 는 단 몇 건의 이상치가 전체 통계를 지배.

Next Action: `np.log1p()` 로그변환 대상 컬럼 10개 확정. 로그변환 전에 물리적으로 불가능한 값(거리>1000마일, 음수 요금 등)은 반드시 별도 처리.

7. 상관관계 히트맵 & 산점도

관찰

- `fare_amount` ↔ `total_amount` : $r = 0.96$ (강한 상관, $|r| > 0.7$ 유일 쌍)
- `trip_distance` ↔ `fare_amount` : $r = 0.01$ — 상식적으로 강한 양의 상관이 기대되지만 전체 데이터에서는 거의 무상관



- 산점도(거리<50마일, 요금<\$200로 필터링한 부분집합)에서는 오히려 뚜렷한 양의 선형 관계가 보임, JFK 고정요금(RatecodeID=2)은 거리 무관하게 \$70 부근 수평선을 형성

trip_distance vs fare_amount (요금 유형별 색 구분, 최대 3만건)




해석: 필터링 전/후 상관계수가 극단적으로 다른 것 자체가 중요한 발견. 극단 이상치(307,491마일, 음수 요금 등) 소수가 전체 상관계수를 완전히 무력화시킴 — 원본 그대로 상관분석을 하면 실제 관계를 놓칠 수 있다는 경고 사례.

Next Action: 상관분석·회귀분석은 이상치 제거(또는 강건 통계량) 후 재실행 필수. $total_amount \approx fare_amount + \text{부가요금}$ 구조이므로 회귀모델에서 다중공선성 주의.

8. 그룹별 박스플롯 (범주형 vs 수치형)

Quantitative vs Categorical — 그룹별 분포



관찰: 현금 결제(payment_type=2)의 `tip_amount` 가 거의 0에 몰려 있음 (현금 팁은 시스템에 기록되지 않는 구조적 특성).

해석: 팁 관련 분석(평균 팁, 팁 비율 등)에서 현금 결제를 포함하면 왜곡됨.


Next Action: `is_cash` 파생변수를 만들어 팁 분석 시 신용카드 결제(`payment_type=1`)만 필터링.

9. 핵심 인사이트 시각화 (Q1~Q3)

관찰


- Q1 시간대:** 17~18시에 최고점(약 28만 건), 새벽 3~6시가 최저(3~4만 건). 다만 오전 7~9시는 완만한 증가 구간일 뿐 뚜렷한 "출근 피크"로 보긴 어렵고, 단일 피크(17~18시) 형태에 가까움 — 노트북에 적힌 "7~9시/17~19시 이중 피크" 가정과는 다소 차이가 있음

Q1. 시간대별 트립 수 — 러시아워 패턴




- **Q2 결제방식별 팁:** 신용카드는 넓은 분포를 보이는 반면 현금은 거의 0에 고정 (Part 8 관찰과 일치)

Q2. 결제 방식별 팁 금액 분포 (5만건 샘플)



- **Q3 요일:** 주중/주말 패턴 확인 가능 (차트 참고)

Q3. 요일별 트립 수




해석: `is_rush_hour` 파생변수를 만든다면 기존 가정(7-9시, 17-19시)보다 **17-19시 위주로 가중**을 두는 것이 실제 데이터에 더 부합.

Next Action: `is_rush_hour` 정의를 실제 시간대별 분포에 맞게 재검토.

10. Borough(자치구) 위치 분석

Borough별 분석




관찰

Borough	트립 수	평균 total_amount
Manhattan	3,537,655 (86.5%)	\$26.50
Queens	351,348	\$67.19
Brooklyn	158,842	\$35.22
Bronx	35,669	\$37.38
Unknown	4,734	\$36.83
EWB(뉴욕 공항)	504	\$113.70
Staten Island	332	\$49.64

픽업 상위 Zone: Upper East Side South(198,008건) > Upper East Side North > Midtown Center > **JFK Airport(149,312건)** 순.

픽업 트립 수 상위 10 Zone



해석: 트립 수는 Manhattan에 압도적으로 집중되지만, 평균 요금은 공항(EWR \$113.7, Queens \$67.2 — JFK 포함)이 훨씬 높음. "트립이 많은 곳"과 "매출 기여도가 높은 곳"이 다르다는 전형적 패턴.

Next Action: 매출 관점 분석 시 Borough별 트립 수가 아닌 (트립 수 × 평균 요금) 총 매출 기준으로 재정렬 필요.

11. 종합 결론 — 정제(Cleaning) 설계에 반영할 사항

1. 결측 5종은 개별 대체 금지, 그룹 단위로 접근 — `payment_type=0` 행 자체가 별도 레코드 유형
2. 물리적으로 불가능한 값 우선 제거: `trip_distance` 상한(예: 100마일), 음수 금액, 소요시간 ≤ 0
3. 로그변환 대상 10개 컬럼 확정 (Part 6 참고) — 단, 이상치 제거 후 적용
4. `LABEL_MAP` 갱신 필요: `VendorID 6/7`, `payment_type 0`
5. 상관/회귀분석은 반드시 이상치 제거 후 재실행 — 원본 그대로면 `trip_distancefare_amount` 관계처럼 실제 신호가 사라짐
6. `is_rush_hour`, `is_cash` 등 파생변수 정의를 실제 분포 기준으로 재검토